SMARTDESK AI: HỆ THỐNG TRỢ LÝ CSKH THÔNG MINH

Advanced Agentic & Applied AI Systems — Final Project Defense (2026–2027)

Dev B & Integrator

- Dương Bắp Vịt Hoàng (23110020)
- GitHub: @BapVitHoang
- Platform, Database, Docker Compose
- OAuth2 / HS256 JWT, RBAC & Governance

Dev A (AI Engine & Eval)

- Nguyễn Nhật Huy (23110029)
- GitHub: @TheOrijinnn
- RAG Pipeline, 4 Agent Tools
- Single-Call Pydantic, 24-Case Eval

Dev C (Frontend UX & QA)

- Trần Quốc Khánh (23110034)
- GitHub: @TKhanh
- React 19 SPA, Tailwind CSS v4
- Telemetry Panel, QA Acceptance & Docs

Bối Cảnh Thực Tế & Thách Thức Trong CSKH

Áp Lực CSKH Truyền Thống

- >60% yêu cầu lặp lại: Đổi trả, bảo hành, reset 2FA, biểu phí dịch vụ.
- First Response Time (FRT) kéo dài > 4–6 giờ, gây sụt giảm chỉ số CSAT.
- Chi phí nhân sự phình to khi mở rộng hỗ trợ 24/7 theo quy mô khách hàng.
- Áp lực trả lời liên tục dễ gây sai sót thông tin và mâu thuẫn cam kết.

Hạn Chế Của Chatbot AI Thông Thường

- Rủi ro ảo giác (Hallucination): Tự ý bịa đặt chính sách bảo hành hoặc SLA.
- Nút thắt hạn mức API (HTTP 429 Rate Limit): Làm tê liệt hoàn toàn hệ thống.
- Thiếu nguồn trích dẫn: Khách hàng không thể kiểm chứng tính xác thực.
- Không kiểm định tài liệu: Nạp thẳng tài liệu lỗi, mâu thuẫn vào cơ sở tri thức.

GIẢI PHÁP NỀN TẢNG

Giải Pháp Toàn Diện: SmartDesk AI Platform

1. Khách Hàng (Customer RAG)

- Hỏi đáp tri thức tự nhiên với độ trễ < 1,500ms.
- Trích dẫn nguồn minh bạch (Citation Badges [Doc #ID]).
- SSE Token-by-token streaming mượt mà.
- Hàng rào chặn Injection song ngữ EN/VI tại Gateway.
- Gửi ticket hỗ trợ chuẩn hóa mã #TICK-XXXX.

2. Hỗ Trợ Viên (Agent Copilot)

- Hàng đợi ticket đa tiêu chí (Sắp xếp, phân trang, lọc).
- AI Copilot tự động phân loại danh mục nghiệp vụ.
- Tính hạn cam kết SLA chuẩn xác (2h/4h/8h/24h).
- Soạn sẵn bản thảo phản hồi tiếng Việt có căn cứ.
- Hỗ trợ xóa ticket an toàn với xác nhận quản trị.

3. Quản Trị Viên (Active Studio)

- Không gian làm việc đa domain (Multi-Tenant).
- Nạp tài liệu động (.pdf, .txt, .md) chia 700 chars.
- Studio Sát hạch 3 tác tử (Faithfulness Score >= 85%).
- Bảng giám sát AI Telemetry theo dõi token & chi phí thực.
- Mạch ngắt Cost-Guard Circuit Breaker bảo vệ ngân sách.

YÊU CẦU & ĐẶC TẢ HỆ THỐNG

12 User Stories & Ma Trận Truy Vết Yêu Cầu (RTM)

12 Câu Chuyện Người Dùng (US-01 .. US-12)

- US-01: Tra cứu RAG kèm trích dẫn tài liệu minh bạch.
- US-02: Dự phòng Okapi BM25 khi ngắt mạch LLM.
- US-03: Hàng rào chắn Prompt Injection & Out-of-Scope.
- US-04: Tạo ticket kèm cam kết SLA 2h/4h/8h/24h.
- US-05: AI Copilot gán nhãn & gợi ý bản thảo trả lời.
- US-06: Sắp xếp, phân trang & xóa ticket hàng đợi.
- US-07: Cách ly tri thức đa Workspace (0% rò rỉ chéo).
- US-08: Ingestion tài liệu tự động chia đoạn 700 chars.
- US-09: Sát hạch độ trung thực tài liệu bằng 3 tác tử.
- US-10: Dual AI (Gemini + Ollama) & Cost-Guard 429.
- US-11: Xác thực JWT HS256 & phân quyền vai trò RBAC.
- US-12: SSE Token Streaming & Thẻ xác nhận 2 pha.

Cam Kết Ma Trận Truy Vết (Traceability)

- 100% User Stories liên kết trực tiếp tới API, UI & Tests.
- Mỗi tính năng đều có ít nhất 1 bài test tự động tương ứng.
- Đường dẫn mã nguồn & tên hàm kiểm thử có thật trong repo.
- Đáp ứng hoàn hảo yêu cầu Understanding Gate (CRIT-08).
- Bộ test test_api.py và common/ đạt tỷ lệ Pass 14/14.

KIẾN TRÚC HỆ THỐNG

Kiến Trúc Tổng Thể Hệ Thống (Architecture Overview)

Lớp Frontend (React 19 SPA)

- React 19 + Vite 6 + Tailwind CSS v4.
- Tổ chức features/ theo lane sở hữu nghiêm ngặt.
- Hỗ trợ SSE Streaming token trực tiếp.
- Thẻ xác nhận hành động nhạy cảm 2 pha.
- Chuyển đổi vai trò Admin / User 1-click.

Lớp Backend (FastAPI Async ASGI)

- Python 3.11+ bất đồng bộ 100% (Async/Await).
- Hàng rào bảo mật Gateway (Bilingual Guardrails).
- Mã hóa PII (Email, SĐT, CCCD) trước khi gọi LLM.
- RAG Hybrid (Cosine vector + Okapi BM25).
- Xác thực HS256 JWT, chống timing user enumeration.

Lớp Lưu Trữ & AI Engine

- PostgreSQL 16 + pgvector (⇔ Cosine distance).
- Async SQLite fallback cho local development.
- Cloud: Google Gemini 3.5 Flash Lite + gemini-embedding-001.
- Local: Ollama Qwen2.5 3B + nomic-embed-text.
- Offline: Okapi BM25 phi AI trên seed_faq.json.

THIẾT KẾ KIẾN TRÚC

4 Quyết Định Kiến Trúc Then Chốt (ADR-001 .. ADR-004)

ADR-001: Dual AI Provider & BM25 Fallback

- Chống sập khi hết quota Cloud: Gemini → Ollama → Okapi BM25.
- Cơ chế ngắt mạch 60s khi gặp HTTP 429 Rate Limit.

ADR-002: Dual-Engine Vector Store

- PostgreSQL pgvector cho Production, Async SQLite cho local dev.
- SQLAlchemy Vector(768).with_variant(JSON(), 'sqlite').

ADR-003: 3-Agent Active Verification

- Synthetic QA Exam → Sandbox RAG → Faithfulness Judge.
- Ngăn chặn tài liệu sai lệch được xuất bản ra môi trường phục vụ.

ADR-004: React 19 SPA Thay Vì Next.js

- Độc lập hoàn toàn với Backend qua REST/SSE, không dính SSR lock.
- Build tĩnh siêu nhẹ (< 420 KB), deploy tức thì trên Nginx.

THIẾT KẾ AI CHUYÊN SÂU

Mô Hình AI & Quản Lý Prompt Tập Trung (prompts.json)

Mô Hình Ngôn Ngữ & Embedding

- Primary Cloud LLM: Google Gemini 3.5 Flash Lite (GA).
- Cấu hình thinking_budget=0: Độ trễ phản hồi < 1,200ms.
- Secondary Fallback: gemini-2.5-flash-lite khi model chính lỗi.
- Vector Embedding: gemini-embedding-001 (768 chiều vector).
- Local Provider: Ollama qwen2.5:3b + nomic-embed-text.

Quản Lý Prompt Tập Trung (prompts.json)

- 8 mẫu Prompt phiên bản hóa trong backend/data/prompts.json.
- Hot-reload tự động phát hiện thay đổi mtime không cần restart.
- 3 Persona chuyên biệt: IT SaaS, SmileCare, TechStore.
- Enforce nhiệt độ temperature=0.2 cho RAG chính xác.
- Dễ dàng biểu diễn kịch bản thay đổi trực tiếp (Live Change).

HỆ THỐNG TÁC TỬ (AGENTIC AI)

4 Agent Tools & Thẻ Xác Nhận 2 Pha (Capability B)

4 DB-Backed Agent Tools (agent_tools.py)

- 1. lookup_customer_tickets: Tra cứu trạng thái phiếu của khách.
- 2. search_workspace_knowledge: Tìm kiếm kiến thức chuyên sâu.
- 3. create_escalation_ticket: Khởi tạo phiếu khi cần người can thiệp.
- 4. update_ticket_priority_or_status: Đổi độ ưu tiên / trạng thái.

Cơ Chế Xác Nhận 2 Pha (Two-Phase Execution)

- Các công cụ ghi dữ liệu (Mutating tools) KHÔNG tự động thực thi.
- Tạo đối tượng PendingActionSchema với action_id duy nhất.
- Hiển thị Thẻ Xác Nhận trực quan trên giao diện chat.
- Khách hàng bấm [Xác nhận thực thi] → POST /chat/confirm-action.
- Khách hàng bấm [Hủy bỏ] → Hành động bị hủy, database an toàn.

CHUẨN HÓA DỮ LIỆU ĐẦU RA

Định Dạng Đầu Ra Cấu Trúc Bằng Pydantic v2 (Capability C)

Schema TicketCopilotStructuredOutput

- category: Authentication, Billing, Bug Report, Feature Request, General.
- priority: Urgent (2h), High (4h), Medium (8h), Low (24h).
- estimated_response_hours: Số nguyên cam kết chuẩn mực.
- ai_tags: 1 đến 4 thẻ tóm tắt ngắn gọn.
- confidence: Điểm tin cậy từ 0.0 đến 1.0.
- ai_draft_reply: Bản thảo câu trả lời tiếng Việt chỉn chu.

Single-Call Triage & Normalization

- Chỉ 1 lượt gọi LLM duy nhất: Vừa phân loại vừa soạn bản thảo.
- Tiết kiệm 50% chi phí token và giảm 50% độ trễ tổng thể.
- @field_validator tự động chuẩn hóa 'Technical Bug' → 'Bug Report'.
- Fail-closed fallback: Gọi hàm dựng bản thảo cục bộ khi LLM lỗi.
- 100% dữ liệu tuân thủ kiểu nghiêm ngặt, không dùng dict tự do.

THẨM ĐỊNH TRI THỨC CHỦ ĐỘNG

Studio Sát Hạch Tri Thức 3 Tác Tử (Active Verification)

1. Synthetic QA Agent

- Đọc hiểu toàn bộ các chunk của tài liệu tải lên.
- Tự động sinh ra bộ câu hỏi sát hạch thử thách.
- Kèm câu trả lời chuẩn (Ground Truth) trích từ nội dung.

2. Sandbox RAG Agent

- Gửi câu hỏi thử thách vào môi trường RAG độc lập.
- Thực thi song song qua asyncio.gather().
- Thu thập câu trả lời thực tế và các trích dẫn tài liệu.

3. Faithfulness Judge

- Đối soát câu trả lời thực tế với tài liệu gốc.
- Chấm điểm trung thực (Faithfulness Score 0–100%).
- Chỉ tài liệu đạt >= 85% mới được phép xuất bản vào RAG.

AN TOÀN & BẢO MẬT DỮ LIỆU

An Toàn Bảo Mật, Hàng Rào Chắn & Quyền Riêng Tư

Hàng Rào Chặn Prompt Injection Song Ngữ

- Phát hiện jailbreak tiếng Anh: 'Ignore previous instructions', 'DAN mode'.
- Phát hiện jailbreak tiếng Việt: 'Bỏ qua tất cả hướng dẫn', 'Nhà phát triển'.
- Chặn đứng tại Gateway trong 0.05ms trước khi tới Database hay LLM.
- Trả về HTTP 400 PROMPT_SECURITY_VIOLATION chuẩn hóa.
- Tiết kiệm 100% token khi gặp cuộc tấn công ác ý.

Chính Sách Xóa Mờ Dữ Liệu Cá Nhân (redact_pii)

- Email: nguyen.an@company.vn → [REDACTED_EMAIL].
- Số điện thoại Việt Nam: 0912345678 → [REDACTED_PHONE].
- CCCD / CMND: 079098765432 → [REDACTED_ID].
- Thực hiện trước khi gọi Gemini API và trước khi tạo Vector Embedding.
- Bảo toàn giá tiền và mã ticket trong câu hỏi.

KHẢ NĂNG CHỊU LỖI & SẴN SÀNG

Cost-Guard Circuit Breaker & Dự Phòng Okapi BM25

Mạch Ngắt Cost-Guard Circuit Breaker

- Kích hoạt khi gặp lỗi Google Gemini HTTP 429 ResourceExhausted.
- Tự động khóa Cloud API trong 60 giây (cooldown_until = now + 60s).
- Bảo vệ tài khoản khỏi cascade failure và chi phí phát sinh.
- Giao diện Telemetry hiển thị cờ cảnh báo màu cam rõ ràng.
- Cung cấp nút [Mở Khóa Cooldown 429] 1-click để reset tức thì.

Dự Phòng Okapi BM25 Hoàn Toàn Phi AI

- Bộ so khớp từ khóa thuần Python trên seed_faq.json và custom chunks.
- Phản hồi siêu tốc trong 12ms – 18ms khi Cloud AI gặp sự cố.
- Trả về flag is_fallback: true và banner hướng dẫn khách hàng.
- Gợi ý nút chuyển tiếp sang Ticket CSKH nếu chưa thỏa mãn.
- Đảm bảo hệ thống đạt tính sẵn sàng 100% trong mọi tình huống.

ĐÁNH GIÁ THỰC NGHIỆM

Kết Quả Thực Nghiệm Bộ 24 Test Cases (Benchmark)

Đột Phá Tỷ Lệ Pass Rate (Before vs. After)

- Normal (In-Scope, RAG & Tools): 50.0% → 100.0% (10/10).
- Edge (Không dấu, PII, Đa ý, Schema): 16.7% → 100.0% (6/6).
- Should-Refuse (Prompt Injection & Out-of-Scope): 25.0% → 100.0% (8/8).
- Tổng thể toàn bộ benchmark: 33.3% (8/24) → 100.0% (24/24).
- Cải thiện ấn tượng +66.7% (+16 test cases đạt chuẩn).

Hiệu Năng Độ Trễ & Chi Phí Vận Hành

- Độ trễ trung bình câu hỏi thường (Gemini 3.5): 920ms – 1,350ms (< 1,500ms).
- Độ trễ chế độ dự phòng BM25: 12ms – 18ms.
- Thời gian chặn Prompt Injection tại Gateway: 0.05ms.
- Chi phí ước tính: $0.00018 – $0.00035 USD / lượt tương tác.
- Dữ liệu kiểm chứng thực tế tại docs/notes/A-eval-report.md.

QUẢN TRỊ & PHÂN QUYỀN

Xác Thực JWT HS256 & Phân Quyền Vai Trò (RBAC)

Bảo Mật Xác Thực & Chống Lỗ Hổng

- Mã hóa HS256 JWT chuẩn mang claims: sub, role, user_id, exp, iat.
- Xác thực chứng chỉ công khai JWKS Google OAuth2 (Commit eef0af8).
- Băm mật khẩu bằng scrypt kèm hằng số thời gian chống timing attacks.
- Giới hạn tốc độ đăng nhập (login_throttle): 10 lần sai → HTTP 429.
- Bộ test bảo mật chuyên biệt: backend/tests/platform/test_auth_security.py.

Phân Quyền Vai Trò (Admin vs User)

- Khách hàng (User): Chỉ tra cứu và nhìn thấy các ticket của chính mình.
- Hỗ trợ viên (Admin): Toàn quyền duyệt queue, xóa ticket, quản trị tri thức.
- Khách hàng truy cập route Agent → HTTP 403 Forbidden.
- Giao diện tự động ẩn và khóa Tab 3 (Agent) & Tab 4 (Knowledge) khi là User.
- Bộ chuyển đổi 1-click thuận tiện cho quá trình chấm thi và demo.

TỔNG KẾT & ĐỊNH HƯỚNG

Kết Luận & Định Hướng Phát Triển Tương Lai

Thành Tựu Của Dự Án SmartDesk AI

- Hoàn thiện 100% 12 User Stories và toàn bộ ma trận RTM.
- Thời gian phản hồi RAG đạt chuẩn SLA đề tài (< 1,500ms).
- Cơ chế dự phòng BM25 và ngắt mạch Cost-Guard loại bỏ hoàn toàn downtime.
- Studio Sát hạch Tri thức 3 tác tử tiên phong chống ảo giác dữ liệu.
- Toàn bộ 100% bài kiểm thử Backend & Frontend passed sạch sẽ.

Định Hướng Phát Triển

- Multimodal Document Processing: Dùng Gemini Vision đọc biểu đồ PDF.
- Reranker Chuyên Sâu: Tích hợp Cohere Rerank / BGE-Reranker tăng độ chuẩn.
- Omnichannel Integration: Mở rộng webhook kết nối Zalo, Telegram, Slack.
- Distributed Task Queue: Tích hợp Celery + Redis khi lượng tài liệu tăng cao.