SMARTDESK AI
Hệ Thống Trợ Lý Hỗ Trợ Khách Hàng Thông Minh & Tự Động Hóa Tri Thức Đa Doanh Nghiệp

Môn học: Các Hệ thống AI Ứng dụng & Agentic Nâng cao (2026–2027)
Thành viên thực hiện (Thông tin chính thức từ docs/TEAM_ROSTER.md):
• Ngô Việt Hoàng (MSSV: 23110020) — Dev B & Integrator (@BapVitHoang)
• Lê Nguyên (MSSV: 23110043) — Dev A (@TheOrijinnn)
• Tống Gia Khánh (MSSV: 23110032) — Dev C (@TKhanh)
Báo cáo và tài liệu cuối kỳ được Hoàng tổng hợp với sự hỗ trợ của AI agent và được cả nhóm rà soát.

2. VẤN ĐỀ & ĐỘNG LỰC THỰC TẾ
Những Thách Thức Lớn Trong Vận Hành Chăm Sóc Khách Hàng (CSKH)

• Áp lực quá tải câu hỏi lặp lại: Hơn 60% yêu cầu liên quan đến các chính sách quen thuộc (hoàn tiền, 2FA, đổi trả).
• Thời gian phản hồi đầu tiên (FRT) kéo dài: Trung bình từ 4 đến 12 giờ, gây giảm sút mức độ hài lòng khách hàng (CSAT).
• Rủi ro AI ảo giác (Hallucination): Chatbot thông thường tự ý bịa đặt chính sách bảo hành hoặc cam kết sai thời hạn SLA.
• Nguy cơ gián đoạn dịch vụ khi quá tải Cloud: Các hệ thống chỉ dựa vào một LLM Cloud dễ bị lỗi 429 Resource Exhausted làm tê liệt kênh hỗ trợ.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 2 / 15

3. GIẢI PHÁP SMARTDESK AI
Nền Tảng Tự Động Hóa Hỗ Trợ Khách Hàng Đa Doanh Nghiệp Toàn Diện

• Customer RAG Chatbot: Phản hồi độ trễ thấp (< 1,500ms) kèm trích dẫn nguồn minh bạch (Citation Badges) từng trang tài liệu.
• Active Knowledge Verification Studio: Quy trình 3 tác tử tự động kiểm định độ trung thực trước khi xuất bản tài liệu.
• AI Copilot Hỗ trợ Nhân viên: Tự động phân loại danh mục, tính cam kết SLA và soạn sẵn bản thảo trả lời tiếng Việt.
• Deterministic Non-AI Fallback: Bộ so khớp Okapi BM25 phi AI trên 12 FAQ chuẩn kết hợp mạch ngắt Cost-Guard Cooldown 60s.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 3 / 15

4. 12 USER STORIES & MA TRẬN TRUY VẾT (RTM)
Bao Phủ Toàn Diện Khách Hàng, Hỗ Trợ Viên & Quản Trị Viên (REQ-24, REQ-25)

• 12 User Stories chuẩn mực (US-01 đến US-12) tuân thủ cấu trúc 'As a... I want... So that...' kèm tiêu chí chấp nhận cụ thể.
• Khách hàng: US-01 (RAG Q&A;), US-02 (BM25 Fallback), US-04 (Tạo Ticket & SLA), US-12 (SSE Streaming & Thẻ xác nhận 2 pha).
• Nhân viên CSKH: US-05 (AI Copilot Triage), US-06 (Sắp xếp, Lọc danh mục, Phân trang & Xóa ticket).
• Quản trị viên: US-07 (Workspaces đa tenant), US-08 (Nạp tài liệu PDF/MD), US-09 (Studio sát hạch), US-10 (Dual-Provider), US-11 (RBAC).
• Bảng Ma trận Truy vết Yêu cầu (RTM) 4 cột chuẩn hóa: 100% (42/42) yêu cầu được liên kết mã nguồn và kiểm thử thành công.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 4 / 15

5. KIẾN TRÚC TỔNG THỂ HỆ THỐNG
Phân Tầng Hướng Dịch Vụ Phi Đồng Bộ (Async Architecture — REQ-26)

• Client Layer: React 19 + Vite 6 + Tailwind CSS v4 SPA. Tách biệt hoàn toàn qua API, tốc độ build ~2s, gói bundle gọn nhẹ (< 420 KB).
• Gateway Layer: FastAPI 100% Async ASGI, JWT HS256 Guard, Regex Gateway chặn Prompt Injection trong 0.05ms, mặt nạ hóa PII.
• Core Engine: RAG Orchestrator phân lập workspace, Copilot Structured Output, 4 Agent Tools với PendingAction, 3-Agent Studio.
• Dual AI Layer: Google Gemini 3.5 Flash Lite + Local Ollama Qwen2.5 3B + Okapi BM25 Non-AI Fallback.
• Persistence Layer: PostgreSQL 16 pgvector (<=> cosine distance) trong Docker, tự động fallback sang SQLite async khi dev local.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 5 / 15

6. QUYẾT ĐỊNH THIẾT KẾ KIẾN TRÚC (ADR-001..004)
Các Architecture Decision Records Nền Tảng (REQ-27)

• ADR-001: Dual AI Provider & Deterministic BM25 Fallback — 3 nấc bảo đảm 100% tính sẵn sàng dịch vụ.
• ADR-002: Dual-Engine Vector Store (PostgreSQL pgvector + SQLite) — Tối ưu cho Production đồng thời thân thiện cho Local Dev.
• ADR-003: 3-Agent Active Knowledge Verification Studio — Kiểm định độ trung thực tài liệu trước khi nạp vào RAG (ngưỡng >= 85%).
• ADR-004: Kiến trúc Frontend SPA React 19 + Vite 6 Thay Vì Next.js 14 SSR — Giao diện CSKH stateful, phản hồi streaming mượt mà.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 6 / 15

7. MÔ HÌNH AI & QUẢN TRỊ PROMPT TẬP TRUNG
Tối Ưu Hóa Độ Trễ, Chi Phí & Tính Riêng Tư Đa Doanh Nghiệp (REQ-18, REQ-19)

• Primary Cloud LLM: Google Gemini GA gemini-3.5-flash-lite (thinking_budget=0, temperature=0.2), độ trễ < 1,200ms.
• Mô hình Nhúng Chuẩn hóa: gemini-embedding-001 (768 chiều), tương thích hoàn hảo với nomic-embed-text của Ollama.
• Quản lý Prompt Tập trung: Toàn bộ system prompts được phiên bản hóa trong backend/data/prompts.json và quản lý bằng Git.
• Đa Persona theo Workspace: IT SaaS Enterprise (chuẩn mực), Nha Khoa SmileCare (thấu cảm y khoa), Điện Máy TechStore (đổi trả 30 ngày).

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 7 / 15

8. BỐN AGENT TOOLS & THẺ XÁC NHẬN 2 PHA
Mở Rộng Năng Lực Tác Tử AI Có Kiểm Soát An Toàn (Capability B — REQ-14)

• Tác tử AI hỗ trợ 4 công cụ thực tế: lookup_customer_tickets, create_escalation_ticket, update_ticket_priority_or_status, search_workspace_knowledge.
• Cơ chế Xác Nhận 2 Pha (Two-Phase Execution): Các hành động thay đổi dữ liệu (tạo hoặc đổi ticket) không tự ý thực thi ngay.
• Hệ thống sinh ra PendingAction với action_id duy nhất và hiển thị Thẻ Xác Nhận Thao Tác (Confirmation Card) trên màn hình chat.
• Chỉ khi người dùng nhấp [Xác nhận thực thi], Backend mới chính thức ghi dữ liệu, ngăn ngừa thao tác nhầm lẫn do AI suy luận.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 8 / 15

9. PYDANTIC V2 STRUCTURED OUTPUT
Chuẩn Hóa Dữ Liệu Ticket Triage Bằng Schema Nghiêm Ngặt (Capability C — REQ-15)

• Toàn bộ kết quả phân loại ticket của AI Copilot được ép kiểu nghiêm ngặt bằng schema TicketCopilotStructuredOutput.
• Chuẩn hóa 5 danh mục: Authentication, Billing, Bug Report (chuẩn hóa từ Technical Bug), Feature Request, General.
• Tính cam kết thời hạn SLA chuẩn xác: Urgent (2 giờ), High (4 giờ), Medium (8 giờ), Low (24 giờ).
• Tự động sinh 1–4 nhãn nhận diện (ai_tags), điểm tin cậy (confidence) và bản thảo câu trả lời tiếng Việt (ai_draft_reply).

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 9 / 15

10. STUDIO SÁT HẠCH TRI THỨC 3 TÁC TỬ
Active Knowledge Verification Studio Trước Khi Xuất Bản (Capability E — REQ-17)

• Tác tử 1 — Synthetic QA Exam Agent: Đọc tài liệu và tự động sinh tập câu hỏi - câu trả lời thử thách thực tế.
• Tác tử 2 — Sandbox RAG Runner: Gửi các câu hỏi thử thách vào pipeline RAG cô lập để trích xuất câu trả lời.
• Tác tử 3 — Faithfulness Judge Agent: Đối soát câu trả lời với văn bản nguồn để chấm điểm độ trung thực (Faithfulness Score).
• Chỉ các tài liệu đạt điểm trung thực >= 85% mới được cấp phép xuất bản (published) vào cơ sở tri thức phục vụ khách hàng.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 10 / 15

11. AN TOÀN BẢO MẬT & QUYỀN RIÊNG TƯ DỮ LIỆU
Hàng Rào Chắn Prompt Injection & Chính Sách Ẩn Danh PII (REQ-20, REQ-37)

• Hàng rào Prompt Injection Song ngữ: Hàm check_prompt_injection quét regex phát hiện jailbreak cả Tiếng Anh và Tiếng Việt.
• Chặn đứng tại Gateway trong 0.05ms với mã HTTP 400 (PROMPT_SECURITY_VIOLATION), không tốn token gọi mô hình.
• Chính sách Ẩn danh Thông tin Cá nhân: Hàm redact_pii tự động làm mờ Email, Số điện thoại VN và CCCD/CMND thành [REDACTED_*].
• Dữ liệu khách hàng được làm mờ triệt để trước khi truyền tải đến mô hình nhúng và Google Gemini Cloud.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 11 / 15

12. COST-GUARD CIRCUIT BREAKER & BM25 FALLBACK
Bảo Đảm Tính Sẵn Sàng 100% Khi LLM Gặp Sự Cố (REQ-20, REQ-23)

• Cost-Guard Circuit Breaker: Tự động kích hoạt khi gọi Gemini bị timeout > 4.0s hoặc trả về mã lỗi HTTP 429 Resource Exhausted.
• Hệ thống tự động khóa cổng gọi Cloud trong 60 giây (FREE_TIER_RATE_LIMIT_COOLDOWN) và chuyển sang Okapi BM25 cục bộ.
• Dự phòng phi AI mượt mà: Truy xuất câu trả lời phù hợp nhất từ 12 bài viết FAQ chuẩn trong seed_faq.json chỉ trong 12–18ms.
• Hiển thị thông báo minh bạch, banner đề xuất tạo ticket khẩn cấp, và cung cấp nút mở khóa Cooldown trên Telemetry Dashboard.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 12 / 15

13. KẾT QUẢ THỰC NGHIỆM BỘ 24 TEST CASES
Đột Phá Hiệu Năng Từ Baseline 33.3% Lên 100.0% (REQ-21, REQ-22)

• Bộ dữ liệu đánh giá chuẩn gồm 24 kịch bản (10 Normal, 6 Edge, 8 Should-Refuse) công khai minh bạch (0 held-out cases).
• Tỷ lệ đạt ban đầu (Baseline): 8 / 24 (33.3%) do thiếu hybrid retrieval, chưa có regex Tiếng Việt và lỗi phân tích cú pháp JSON thô.
• Tỷ lệ sau tối ưu (Upgraded): 24 / 24 (100.0%) — Tăng trưởng ngoạn mục +66.7% (+16 test cases đạt chuẩn).
• Bộ kiểm thử tự động Pytest: 139 passed, 2 skipped trong 56.94 giây; chi phí trung bình cực thấp (~$0.00021 USD / truy vấn).

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 13 / 15

14. BẢO MẬT JWT HS256 & PHÂN QUYỀN RBAC
Kiểm Soát Quyền Hạn & Cô Lập Dữ Liệu Khách Hàng Tuyệt Đối (REQ-09, REQ-36)

• Hệ thống xác thực Bearer JWT HS256 có thời hạn và khóa mã hóa bí mật lưu trong backend/.env.
• Phân quyền 2 vai trò chuẩn: admin (Toàn quyền quản trị, triage ticket, sát hạch tri thức) và user (Khách hàng thông thường).
• Cô lập dữ liệu nghiêm ngặt: Khách hàng chỉ xem được các ticket do chính email của mình tạo ra (0% rò rỉ dữ liệu).
• Giao diện Frontend tự động ẩn và khóa các tab Agent Dashboard và Knowledge Studio khi đăng nhập dưới vai trò user.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 14 / 15

15. KẾT LUẬN & ĐỊNH HƯỚNG TƯƠNG LAI
Tổng Kết Đóng Góp, Quyết Định Phạm Vi & Lộ Trình Phát Triển

• Tổng kết thành tựu: Xây dựng trọn vẹn nền tảng CSKH thông minh đáp ứng 100% 42 yêu cầu chuẩn mực và 12 User Stories.
• Ghi nhận giới hạn phạm vi REQ-16: Nhóm tập trung nguồn lực xây dựng 4 năng lực AI cốt lõi (A, B, C, E), quyết định không chọn năng lực D.
• Khắc phục triệt để tồn đọng MRG-DEF-01: Rebuild slide tự động chuẩn hóa nhân sự; giải quyết lệch chiều vector đám mây MRG-DEF-10.
• Định hướng tương lai: Tích hợp Gemini 2.0 Flash Vision đọc biểu đồ PDF, BGE-Reranker nâng cao độ chính xác và kết nối đa kênh Omnichannel.

SmartDesk AI — Bảo Vệ Đồ Án Cuối Kỳ | Advanced Agentic & Applied AI Systems Slide 15 / 15